Мазанов Артем

Домашнее задание 1

Данное домашнее задание я разделил на 3 логические части:

1) *Кроулинг сайта*
2) *Анализ графа сайта*
3) *Анализ текстов статей*

Кроулинг сайта

Кроулинг сайта я делал с помощью **scrapy**. В архиве приложен проект с пауком **wiki_spider.py**, и его настройками **settings.py**. Собственно, паук обходил только сайты, начинающиеся с **https://simple.wikipedia.org/wiki/**, при этом игнорируя ссылки с *namespaces*, за исключением **Category**. Запоминал пройденные страницы, запоминал соответствия для файла **urls**. В конце работы он записывал файл **urls.txt**, в папке **docs** скачанные странице.

Анализ текста

В этом файле я выделяю текст в статьях для последующего анализа. Для этого мы проигнорируем страницы с **"Category:"** в url, так как это страницы со ссылками, не содержащие текста, но для создания графа они необходимы. Для получения текста из страниц уберем таблицы (это спорный момент, но я решил убрать их), описания фотографий, ссылки и выделим текст.

```
In [37]: import requests
         import os
         from bs4 import BeautifulSoup


         html_to_url = dict()
         url_to_html = dict()

         with open('urls.txt', 'r') as f:
             lines = f.read().split('\n')
             for line in lines:
                 elems = line.split('\t')
                 html_to_url[elems[0]] = elems[1]
                 url_to_html[elems[1]] = elems[0]

         for i, file_name in enumerate(os.listdir('docs')):
             if 'Category:' in html_to_url[file_name]:
                 continue
             with open('docs/' + file_name, 'r') as f:
                 soup = BeautifulSoup(f, 'lxml')
                 soup = soup.find(id="mw-content-text")
                 [elem.extract() for elem in soup.find_all('table')]
                 [elem.extract() for elem in soup.find_all('div')]
                 [elem.extract() for elem in soup.find_all('sup',{'class':'reference'})]
                 [elem.extract() for elem in soup.find_all('span',{'class':'mw-editsection'})]
                 text = u' '.join(soup.get_text().split()).encode('utf-8')
                 path = file_name[:-5] + '.txt'
                 with open('txt_docs/' + path, 'w') as ff:
                     ff.write(text)
```

Получили папку **txt_docs** с .txt документами. Теперь соберем статистику по ним. Для начала построим гистограмму распределения размера документов:

```
In [56]: sizes = list()
         for i, file_name in enumerate(os.listdir('txt_docs')):
             sizes.append(float(os.path.getsize('txt_docs/' + file_name)) / 1024)
```

```
In [57]: import matplotlib.pyplot as plt
         %matplotlib inline
```

```
In [58]: num_bins = 50
         plt.figure(figsize = (16,5))
         n, bins, patches = plt.hist(sizes, num_bins, facecolor='blue')
         plt.yscale('log', nonposy = 'clip')
         plt.show()
         print max(sizes)
```

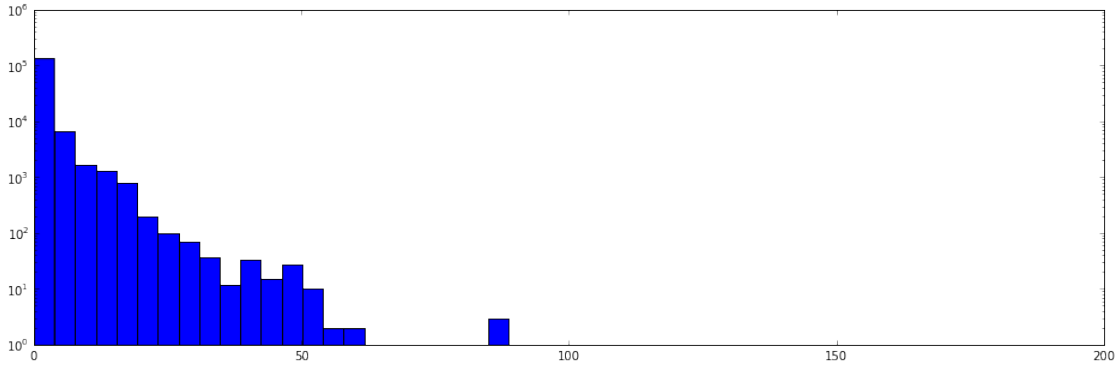


```
192.91015625
```

Далее посчитаем для каждого слова количество его вхождений в коллекцию и построим гистограмму:

```
In [72]: import sys
         import re

         word_stat = dict()
         for i, file_name in enumerate(os.listdir('txt_docs')):
             sys.stdout.write("\rProcessing {0}".format(i))
             with open('txt_docs/' + file_name, 'r') as f:
                 words = re.findall(r'\b[a-z]+\b',f.read().lower())
                 for word in words:
                     if word_stat.get(word) is None:
                         word_stat[word] = 1
                     else:
                         word_stat[word] += 1
```

```
Processing 142903
```

```
In [73]: values = word_stat.values()
```

```
In [87]: num_bins = 50
         plt.figure(figsize = (16,5))
         n, bins, patches = plt.hist(values, num_bins, facecolor='blue')
         plt.yscale('log', nonposy = 'clip')
         plt.show()
         print max(values)
```

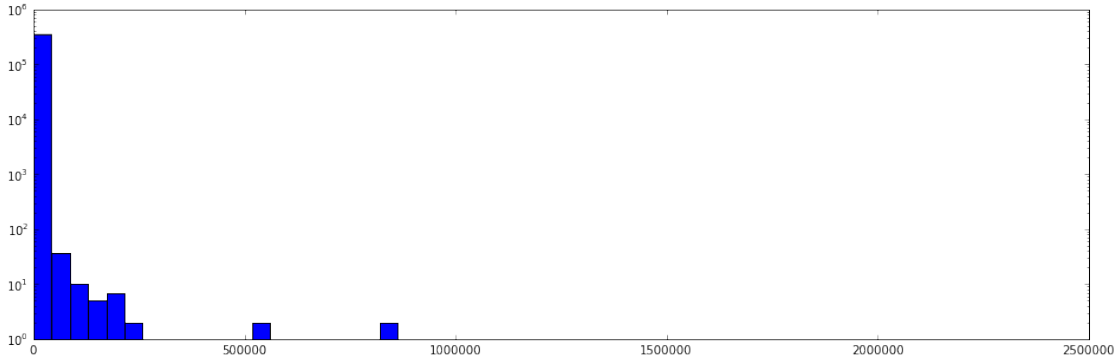


```
2156171
```

```
In [102]: import operator
          sorted_word_stat = sorted(word_stat.items(), key=operator.itemgetter(1), reverse = True)
```

```
In [105]: for word, amount in sorted_word_stat[:20]:
              print word, amount
```

```
the 2156171
of 1074014
in 841986
and 819370
a 710329
to 553942
is 553261
was 333492
it 255385
for 230186
on 207897
are 205857
as 203299
he 194096
by 191568
that 187600
s 179212
with 163306
from 159930
at 143349
```

Как видно, есть несколько слов, которые встречаются **очень** часто и гистограмма очень малоинформативна. Поэтому отсечем хвосты и построим новую гистограмму:

```
In [88]: num_bins = 50
         plt.figure(figsize = (16,5))
         n, bins, patches = plt.hist(values, num_bins, facecolor='blue', range = (0, 40000))
         plt.yscale('log', nonposy = 'clip')
         plt.show()
```

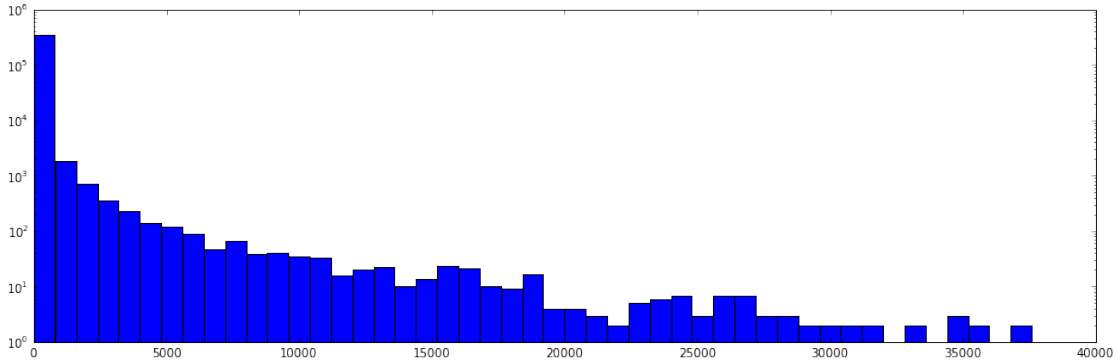

Больше анализа текста не требуется. Анализ графа (in/out, расстояние от главной страницы и диаграмма распределения и PageRank) будут в следующем ipynb

Анализ графа

В данном файле будет анализ графа. Для начала, надо бы построить граф:

```
In [31]: import requests
         import os
         from bs4 import BeautifulSoup
         import copy
         import sys


         html_to_url = dict()
         url_to_html = dict()

         with open('urls.txt', 'r') as f:
             lines = f.read().split('\n')
             for line in lines:
                 elems = line.split('\t')
                 html_to_url[elems[0]] = elems[1]
                 url_to_html[elems[1]] = elems[0]
```

```
In [32]: adj_list_out = dict()
         adj_list_in = dict()
         depths = dict()
         link_list = list()
         new_link_list = list()
         unique_links = set()

         path = html_to_url['1.html']
         link_list.append(path)
         depth = 1
```

```
        count = 0
        while True:
            for path in link_list:
                count += 1
                sys.stdout.write("\rProcessing {0}".format(count))
                depths[path] = depth
                f = open('docs/' + url_to_html[path], 'r')
                soup = BeautifulSoup(f, 'lxml')
                f.close()
                urls = [x.get('href') for x in soup.findAll('a')]
                for link in ['https://simple.wikipedia.org' + x for x in urls if x and x[0] == '/' and
                    if url_to_html.get(link) is not None:
                        if adj_list_out.get(path) == None:
                            adj_list_out[path] = [link]
                        else:
                            adj_list_out[path].append(link)
                        if adj_list_in.get(link) == None:
                            adj_list_in[link] = [path]
                        else:
                            adj_list_in[link].append(path)
                        if link not in unique_links:
                            unique_links.add(link)
                            new_link_list.append(link)
            if len(new_link_list) == 0:
                break
            link_list = copy.copy(new_link_list)
            depth += 1
            new_link_list = []
```

```
Processing 171372
```

```
In [51]: for key in depths:
             depths[key] -= 1
```

Попутно мы собрали немного статистики: в depths лежат глубины при обходе в ширину. В adj_list_in и adj_list_out лежат входящие и выходящие ребра соответственно. Построим гистограмму по глубинам:

```
In [52]: import matplotlib.pyplot as plt
         %matplotlib inline
```

```
In [53]: depth_values = depths.values()
         num_bins = 50
         plt.figure(figsize = (16,5))
         n, bins, patches = plt.hist(depth_values, num_bins, facecolor='blue')
         plt.show()

         plt.figure(figsize = (16,5))
         n, bins, patches = plt.hist(depth_values, num_bins, facecolor='blue')
         plt.yscale('log', nonposy = 'clip')
         plt.show()
         print max(depth_values)
```

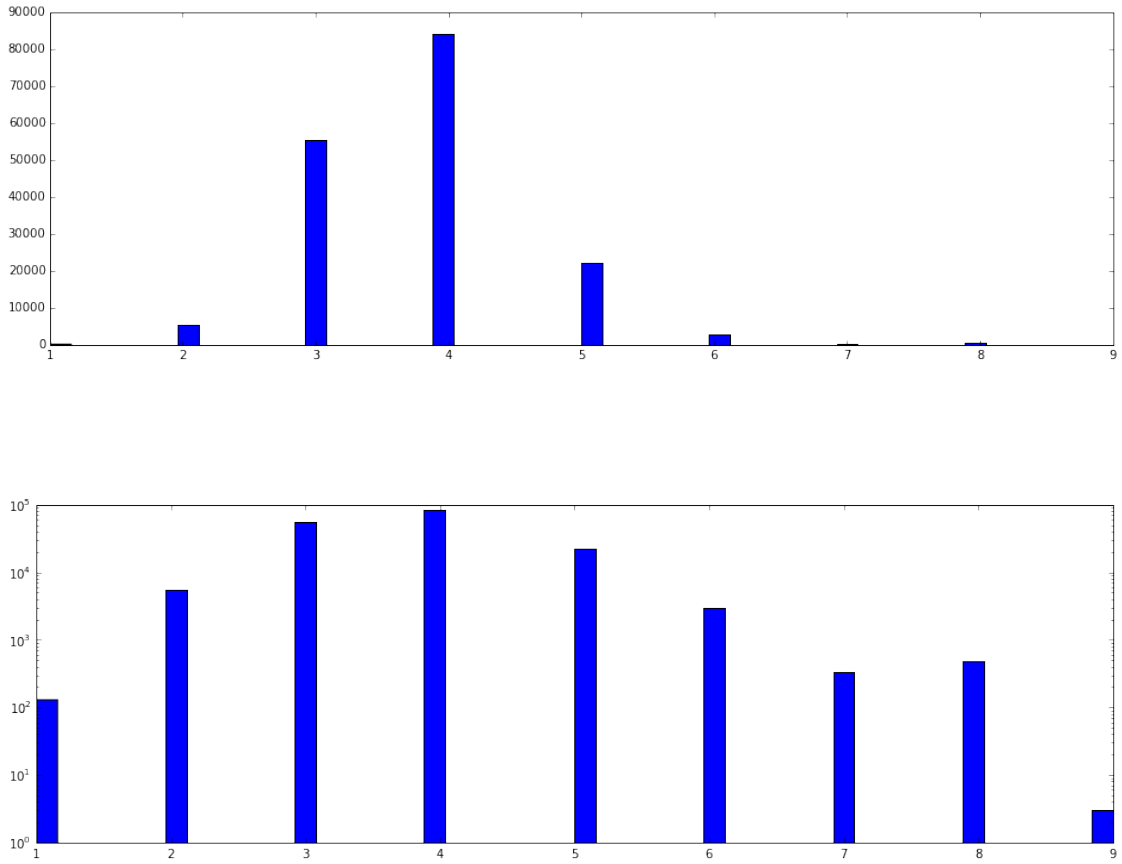

9

Сверху приведена гистограмма с абсолютной и логарифмической шкалами. Так более информативно. Теперь займемся анализом **in степеней вершин**:

```
In [64]: amount_in = dict()
         amount_out = dict()

         for key, value in adj_list_in.items():
             amount_in[key] = len(value)
         for key, value in adj_list_out.items():
             amount_out[key] = len(value)
```

```
In [126]: num_bins = 50
          plt.figure(figsize = (16,5))
          n, bins, patches = plt.hist(amount_in.values(), num_bins, facecolor='blue', range = (0, 15000
          plt.yscale('log', nonposy = 'clip')
          plt.show()
```

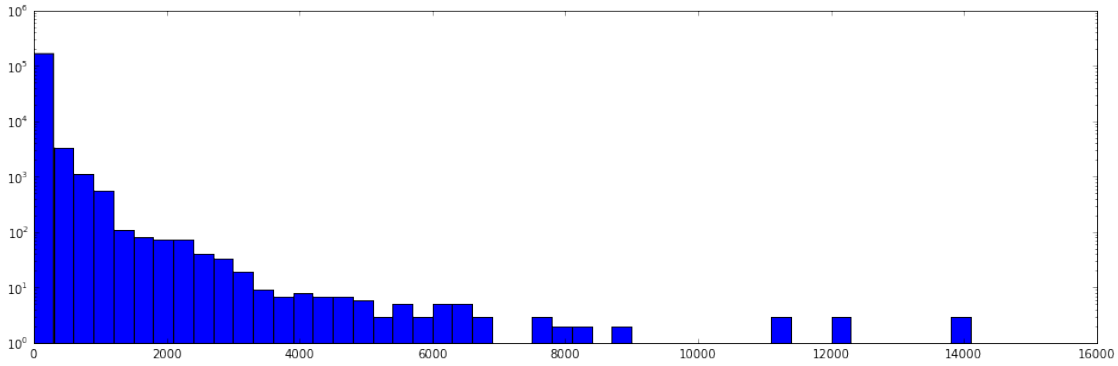


```
In [79]: import operator
         sorted_amount_in = sorted(amount_in.items(), key=operator.itemgetter(1), reverse = True)
```

```
In [80]: for url, amount in sorted_amount_in[:10]:
             print '{0}   {1}'.format(url, amount)
```

```
https://simple.wikipedia.org/wiki/Main_Page   342947
https://simple.wikipedia.org/wiki/United_States   35956
https://simple.wikipedia.org/wiki/Multimedia   29222
https://simple.wikipedia.org/wiki/France   23047
https://simple.wikipedia.org/wiki/Category:Living_people   17618
https://simple.wikipedia.org/wiki/International_Standard_Book_Number   17452
https://simple.wikipedia.org/wiki/Category:People_stubs   15227
https://simple.wikipedia.org/wiki/Germany   14951
https://simple.wikipedia.org/wiki/Category:France_geography_stubs   14156
https://simple.wikipedia.org/wiki/United_Kingdom   14043
```

Как видно, встречаются ссылки типа **Category**. По идее, это страницы со ссылками, не являющиеся статьями. Но для построения графа они важны, поэтому я их оставил. Теперь анализ **out степеней**:

```
In [85]: num_bins = 50
         plt.figure(figsize = (16,5))
         n, bins, patches = plt.hist(amount_out.values(), num_bins, facecolor='blue')
         plt.yscale('log', nonposy = 'clip')
         plt.show()
```

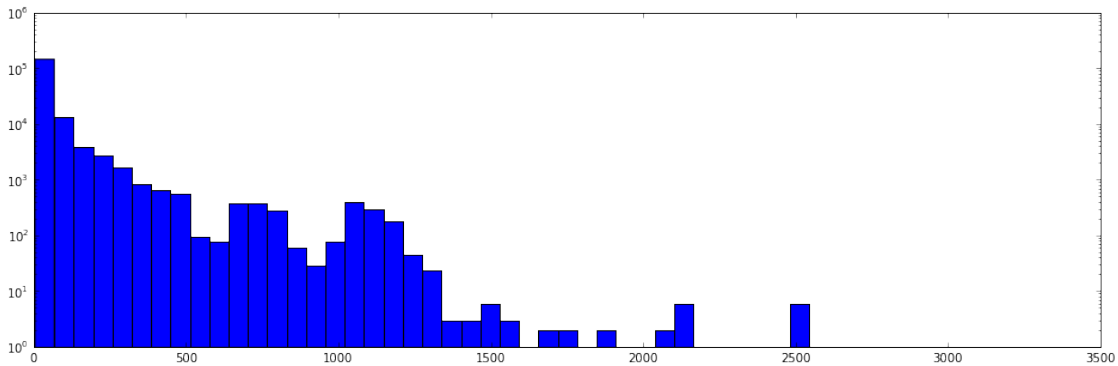

```
In [86]: sorted_amount_out = sorted(amount_out.items(), key=operator.itemgetter(1), reverse = True)

In [89]: for url, amount in sorted_amount_out[:10]:
             print '{0}   {1}'.format(url, amount)
```

```
https://simple.wikipedia.org/wiki/Deaths_in_2013   3181
https://simple.wikipedia.org/wiki/Deaths_in_January_2012   2488
https://simple.wikipedia.org/wiki/Deaths_in_February_2012   2488
https://simple.wikipedia.org/wiki/Deaths_in_March_2012   2488
https://simple.wikipedia.org/wiki/Deaths_in_2012   2488
https://simple.wikipedia.org/wiki/Deaths_in_April_2012   2488
https://simple.wikipedia.org/wiki/Deaths_in_May_2012   2488
https://simple.wikipedia.org/wiki/List_of_Medal_of_Honor_recipients_for_World_War_II   2160
https://simple.wikipedia.org/wiki/2006_in_movies   2135
https://simple.wikipedia.org/wiki/2006_in_film   2135
```

Интересно: Заметим, что со 2-го по 7-е место числа одинаковые. Это потому, что ссылки на самом деле одинаковые и все выходящие ребра повторяются. Такие вещи мы будем находить во втором задании. Теперь посчитаем **Page Rank**:

```
In [115]: amount_of_documents = len(os.listdir('docs'))
          amount_of_documents_without_cat = len(os.listdir('txt_docs'))

In [116]: import copy

          damping_factor = 0.85

          empty_graph = dict()
          prev_graph = dict()
          current_graph = dict()
          for key in adj_list_out.keys():
              empty_graph[key] = (1 - damping_factor) / amount_of_documents
              current_graph[key] = 1 / amount_of_documents
              prev_graph[key] = 1

In [117]: amount_of_iterations = 100

          for i in xrange(amount_of_iterations):
              sys.stdout.write("\rProcessing {0}".format(i))
              for key, value in adj_list_out.items():
                  weight = damping_factor * float(prev_graph[key]) / len(value)
                  for elem in value:
                      current_graph[elem] += weight
              prev_graph = copy.copy(current_graph)
              current_graph = copy.copy(empty_graph)
```

```
Processing 99
```

```
In [118]: graph = copy.copy(prev_graph)

In [119]: sorted_page_rank = sorted(graph.items(), key=operator.itemgetter(1), reverse = True)

In [120]: for url, page_rank in sorted_page_rank[:20]:
              print '{0}   {1}'.format(url, page_rank)
```

```
https://simple.wikipedia.org/wiki/Main_Page   0.0569189798558
https://simple.wikipedia.org/wiki/Multimedia   0.00543725290564
https://simple.wikipedia.org/wiki/United_States   0.00386158705006
https://simple.wikipedia.org/wiki/Category:Stubs   0.00226302510782
https://simple.wikipedia.org/wiki/Category:Geography_stubs   0.0022450975919
https://simple.wikipedia.org/wiki/United_Kingdom   0.00190445104874
https://simple.wikipedia.org/wiki/International_Standard_Book_Number   0.00172751495906
https://simple.wikipedia.org/wiki/Category:Technology_stubs   0.00170271930905
https://simple.wikipedia.org/wiki/France   0.00168571668659
https://simple.wikipedia.org/wiki/Category:People_stubs   0.00161654809608
https://simple.wikipedia.org/wiki/Category:Music_stubs   0.00156174338675
https://simple.wikipedia.org/wiki/Category:Europe_stubs   0.00132814971295
https://simple.wikipedia.org/wiki/Category:Biology_stubs   0.00132269545345
https://simple.wikipedia.org/wiki/Canada   0.0012774244499
https://simple.wikipedia.org/wiki/Definition   0.00125067878329
https://simple.wikipedia.org/wiki/Country   0.00124275184743
https://simple.wikipedia.org/wiki/English_language   0.00116766143595
https://simple.wikipedia.org/wiki/Category:Living_people   0.00116621998378
https://simple.wikipedia.org/wiki/Category:United_States_geography_stubs   0.00110224691137
https://simple.wikipedia.org/wiki/Germany   0.00107695877353
```

Как видно, страницы-категории в топе по Page Rank. Можно их не учитывать. Тогда получаются такие результаты:

```
In [121]: damping_factor = 0.85

          empty_graph = dict()
          prev_graph = dict()
          current_graph = dict()
          for key in adj_list_out.keys():
              empty_graph[key] = (1 - damping_factor) / amount_of_documents_without_cat
              current_graph[key] = 1 / amount_of_documents_without_cat
              prev_graph[key] = 1

In [122]: amount_of_iterations = 100

          for i in xrange(amount_of_iterations):
              sys.stdout.write("\rProcessing {0}".format(i))
              for key, value in adj_list_out.items():
                  if 'Category:' in key:
                      continue
                  weight = damping_factor * float(prev_graph[key])
                  counter = 0
                  for elem in value:
                      if 'Category:' not in elem:
                          counter += 1

                  if counter != 0:
                      weight = weight / counter
                  for elem in value:
                      if 'Category:' not in elem:
                          current_graph[elem] += weight

              prev_graph = copy.copy(current_graph)
              current_graph = copy.copy(empty_graph)
```

```
Processing 99
```

```
In [123]: graph = copy.copy(prev_graph)
```

```
In [124]: sorted_page_rank = sorted(graph.items(), key=operator.itemgetter(1), reverse = True)
```

```
In [125]: for url, page_rank in sorted_page_rank[:20]:
              print '{0}   {1}'.format(url, page_rank)
```

```
https://simple.wikipedia.org/wiki/Main_Page   0.0657119457636
https://simple.wikipedia.org/wiki/United_States   0.00502085770727
https://simple.wikipedia.org/wiki/Multimedia   0.00449821506464
https://simple.wikipedia.org/wiki/United_Kingdom   0.00253175153131
https://simple.wikipedia.org/wiki/International_Standard_Book_Number   0.00224984793048
https://simple.wikipedia.org/wiki/France   0.00222964125044
https://simple.wikipedia.org/wiki/Definition   0.00187662335594
https://simple.wikipedia.org/wiki/Country   0.00178543063521
https://simple.wikipedia.org/wiki/Canada   0.0016128957149
https://simple.wikipedia.org/wiki/English_language   0.00158758396004
https://simple.wikipedia.org/wiki/England   0.001440991184
https://simple.wikipedia.org/wiki/Europe   0.00141760377741
https://simple.wikipedia.org/wiki/Germany   0.00140043968244
https://simple.wikipedia.org/wiki/Japan   0.00136592288026
https://simple.wikipedia.org/wiki/Music   0.00128941321243
https://simple.wikipedia.org/wiki/Government   0.00127781002402
https://simple.wikipedia.org/wiki/Television   0.00123514798363
https://simple.wikipedia.org/wiki/Coordinated_Universal_Time   0.00122949899592
https://simple.wikipedia.org/wiki/Movie   0.00118803089365
https://simple.wikipedia.org/wiki/Geographic_coordinate_system   0.00116378169874
```

Что можно сказать - наличие или отсутствие Category не особо повлияло на порядок остальных страниц. Хотя некоторые перестановки все же есть. И с огромным отрывом лидирует главная страница, что естественно.